吉林大学
JILIN UNIVERSITY

AVC Lab
Affective Vision Computing Lab

Human-JEPA

一个既能感知又能预测的以人为中心视觉模型

Hui Wei · Licai Sun · Guoying Zhao
ELLIS Institute Finland · University of Oulu
arXiv:2608.21160v1· Technical Article

汇报人: 王梦圆
日期: 2026年10月20日



目录

01 研究背景与相关工作

02 问题定义

03 理论基础

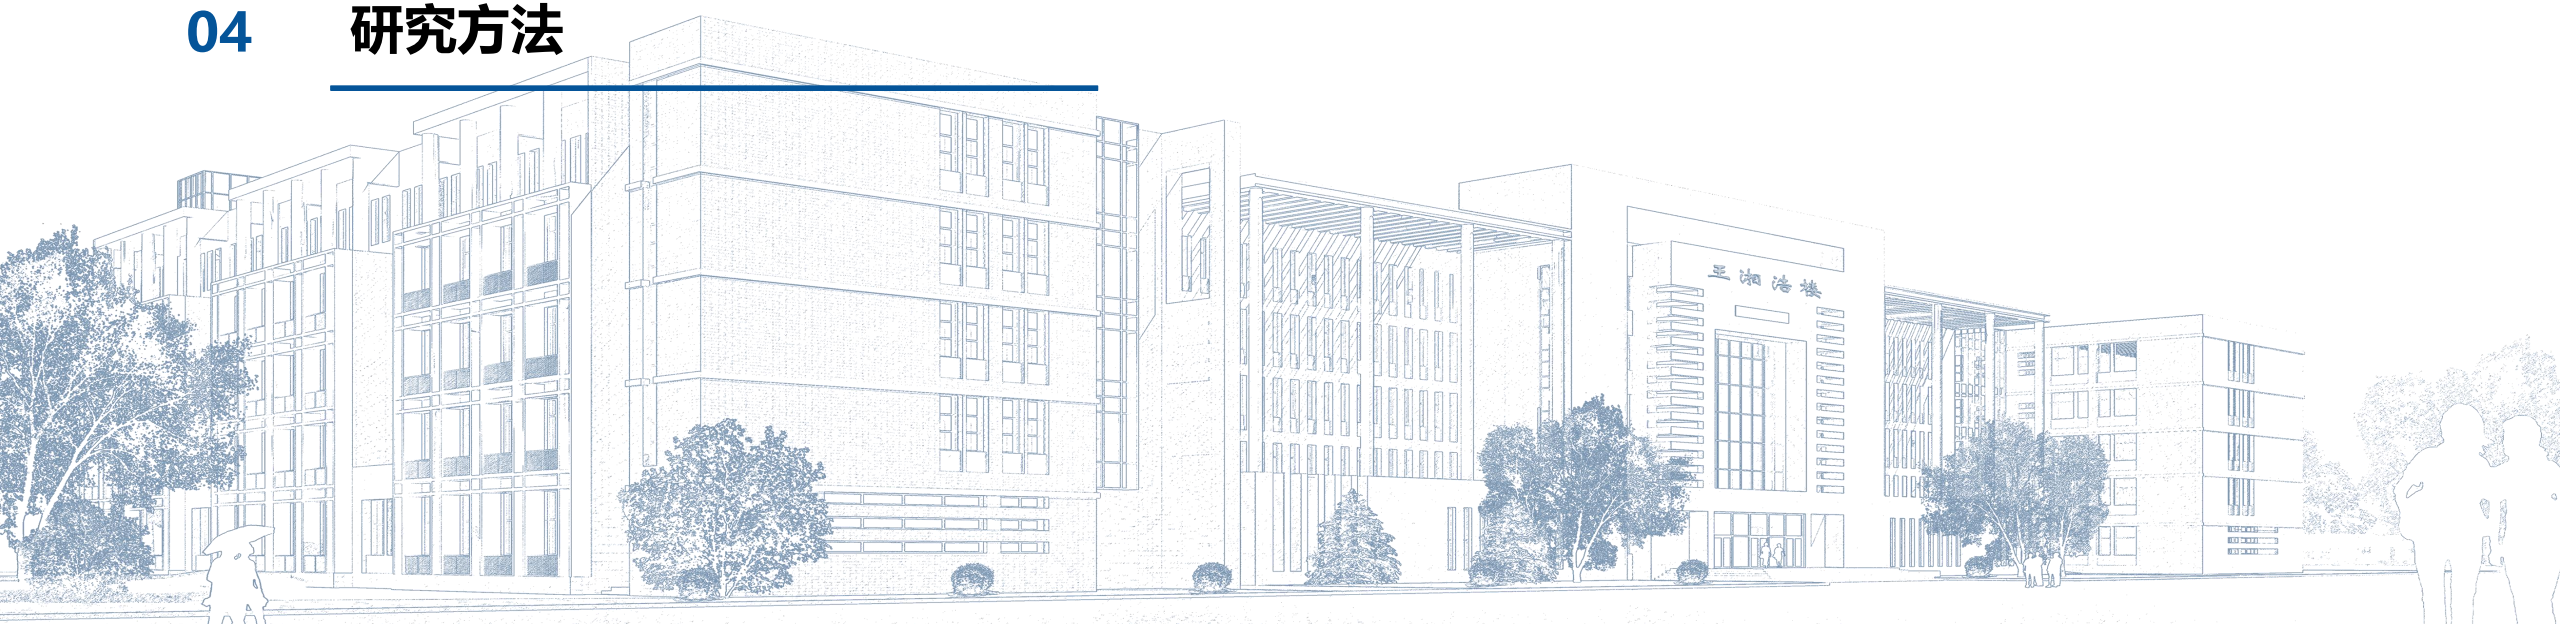
04 研究方法

05 实验与分析

06 总结

AVC Lab

Affective Vision Computing Lab



01

研究背景与相关工作

以人为中心视觉模型：只知"是什么"，不知"接下来怎样"

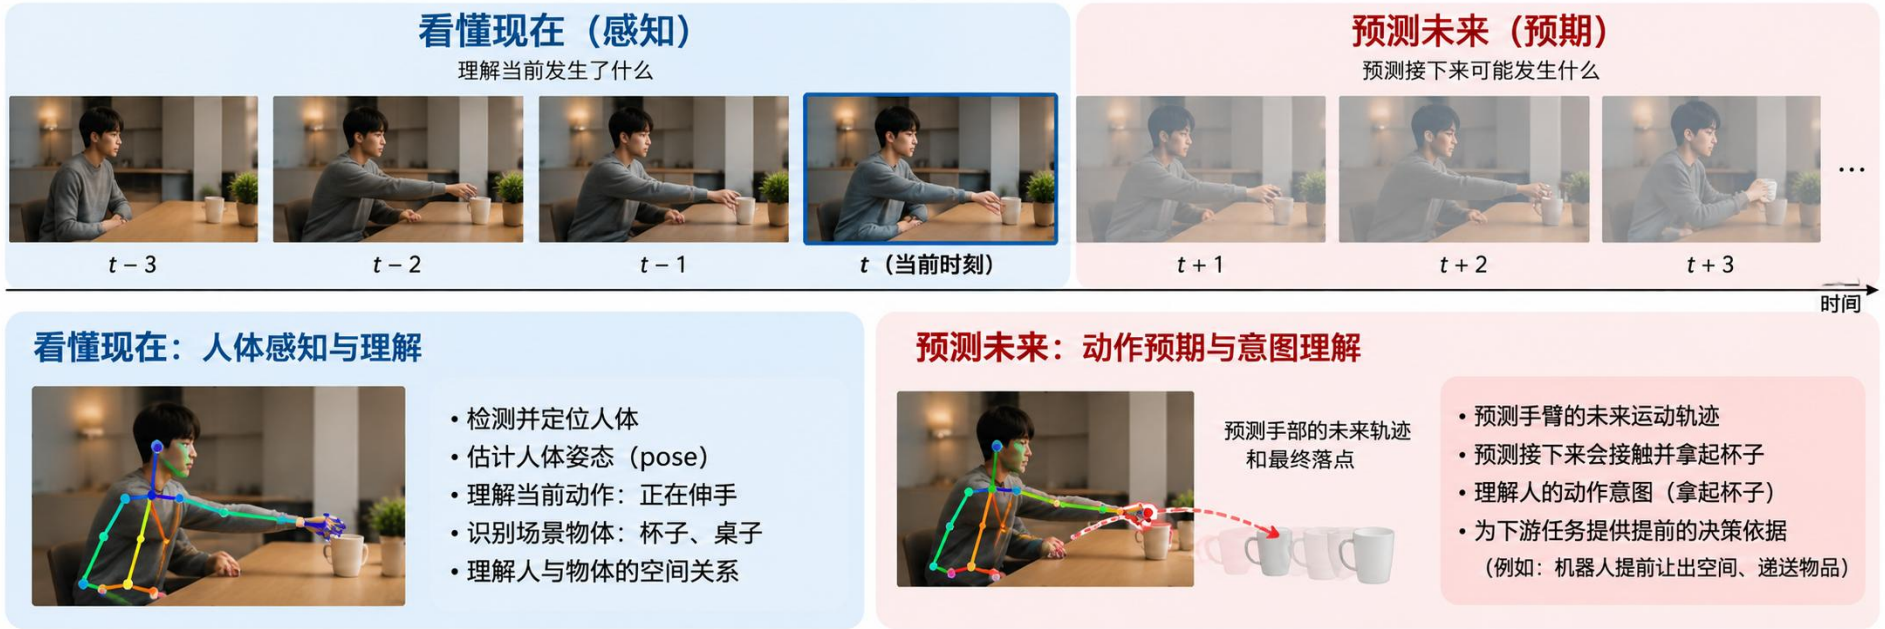
AVC Lab
Affective Vision Computing Lab

现有模型在做什么?

- Sapiens 2 / HAP：静态图像上的人体解析、姿态估计，缺少原生时序建模
- DINOv3：通用视觉基础模型，不专门针对人体，也不是原生视频时序模型
- UniHCP / HuLk：统一的人体多任务模型，但输入仍是单张图像或标注多任务数据，没有视频适配
- **这些human-centric模型主要关注当前人体状态的感知，缺少对人体运动动态和未来状态的显示建模**

缺失了什么?

- 人类视觉 = 感知 + 预测、
- 看到一个人伸手，我们不仅知道他在伸胳膊，还能预测他接下来要做什么。
- 现有模型只完成了前一半——
- **对人体的理解是不完整的。**



相关工作：Human-JEPA 是从哪些研究路线发展出来的?

AVC Lab
Affective Vision Computing Lab

➢ 以人为中心的视觉模型

- **UniHCP / PATH**：共享 backbone + task-specific queries，统一姿态估计、解析、人类重识别等多项视觉任务
- **Sapiens / Sapiens2**：大规模人体图像自监督预训练模型，强化高分辨率的密集表示
- **Hulk**：统一异构2D、3D、基于骨架和视觉语言等人体任务，减少对特定任务头的需求
- **核心瓶颈**：都在单个图像或标记的多任务数据上操作，没有代表人类随时间推移的移动/互动过程!

➢ 自监督范式与JEPA

- **对比学习**：SimCLR、MoCo 依赖数据增强与负样本
- **Distillation-based SSL**：DINO / DINOv2 / DINOv3
- **掩码数据建模**：MAE通过像素重构学习，极易陷入低像素细节
- **联合嵌入预测架构（JEPA）**：I-JEPA → V-JEPA → V-JEPA 2 / 2.1
  - 核心思想：不重建像素，而是在隐空间 latent space 中预测 target representation，避免了低级像素偏置与对比学习的负样本依赖

Human-JEPA：连接静态人体感知与时序预测

AVC Lab
Affective Vision Computing Lab

1 现有人体中心图像模型

Sapiens2



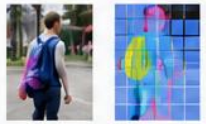
HAP



UniHCP / Hulk



DINOv3 (作为强图像表征参考)



优势

- ✓ 人体解析 (Parsing)
- ✓ 姿态估计 (Pose)
- ✓ 重识别 (ReID)
- ✓ 高分辨率外观细节

局限

- 主要基于单张图像
- 缺乏时序建模
- 无法直接进行未来预测

2 通用视频自监督 / 世界模型

V-JEPA / V-JEPA 2.1



视频世界模型



动作/动力学表征



优势

- ✓ 运动与动态建模
- ✓ 时序表征
- ✓ 可支持 anticipation / planning

局限

- 并非专门面向人体
- 人体 dense feature 不一定最强
- 最终训练可能缺乏高有表征

3 研究空缺



缺少一个同时具备：

- ✓ 高质量人体感知
- ✓ 人体运动/交互建模
- ✓ 未来 anticipation 能力

需要统一的
human-centric video model

Human-JEPA

Frozen Anchor
保持强大的人体图像表征

Image Co-training
图像与视频的联合训练

Past-to-Future Forecasting



基于过去，预测未来的人体运动与交互

Perception
(人体感知)

Identity
(身份表征)

Anticipation
(未来预测)

在保持 dense human perception 的同时，获得面向人体的时序预测能力。

02

问题定义

研究问题

AVC Lab
Affective Vision Computing Lab

1 如何在无人工标注的条件下，将通用模型 JEPA 专项化为human-centric model，使其同时具备高质量人体静态感知（姿态、身份、密集解析）与未来预测能力?

2 如何在 continued pretraining 过程中保留 V-JEPA 2.1 原有的dense perception，避免人体专项化导致表征退化或silent collapse?

3 如何设计预测目标，使模型真正学习人体时序动态，而不是依赖 block masking 中的局部复制 shortcut?



三大核心贡献

AVC Lab
Affective Vision Computing Lab

1 **统一人体感知与未来预测**

构建 Human-JEPA，实现 present perception 与 future anticipation 的统一建模。

2 **锚定继续预训练（Anchored Continued Pretraining）**

将预测目标锚定在初始化时的冻结副本上，配合图像协同训练分支，防止继续预训练导致的静默表示坍塌（identity collapse）。

3 **过去到未来的预测 （Past-to-Future Forecasting）**

用纯过去到未来的预测替代 block inpainting，强化人体时序动态建模并减少 action / identity tax。



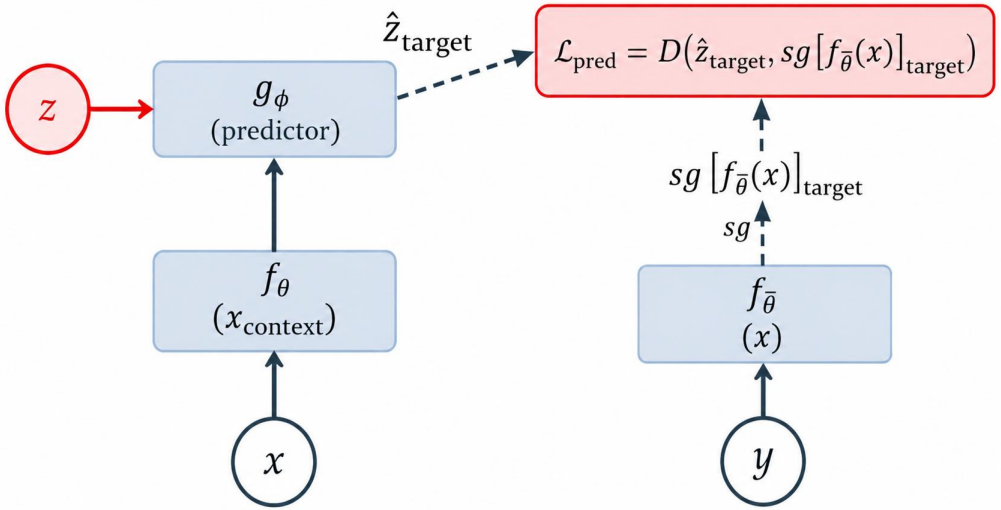
03

理论基础

联合嵌入预测架构（JEPA）

AVC Lab
Affective Vision Computing Lab

给定可见上下文，通过在隐空间 (latent space) 预测缺失区域特征来学习数据的表示。



$$\hat{z}_{\text{target}} = g_\phi(f_\theta(x_{\text{context}}))$$

$$\mathcal{L}_{pred} = \left\| \hat{z}_{target} - sg[f_{\bar{\theta}}(x)]_{target} \right\|_1$$

$$\mathcal{L}_{pred} = \frac{1}{|M|} \sum_{i \in M} \left\| \hat{z}_{target,i} - sg[f_{\bar{\theta}}(x)]_{target,i} \right\|_1$$

学生编码器与预测器接受梯度更新，目标分支通过 EMA 更新。

组件	作用	如何更新
学生编码器f_θ	读取可见上下文（可见图像区域/视频片段）	梯度更新
预测器g_ϕ	接收编码后的上下文+可学习的掩码token→预测目标位置的表示	梯度更新
EMA 教师编码器$f_{\bar{\theta}}$	生成目标特征（缺失区域/未来片段的潜在表示）	EMA 更新，停止梯度

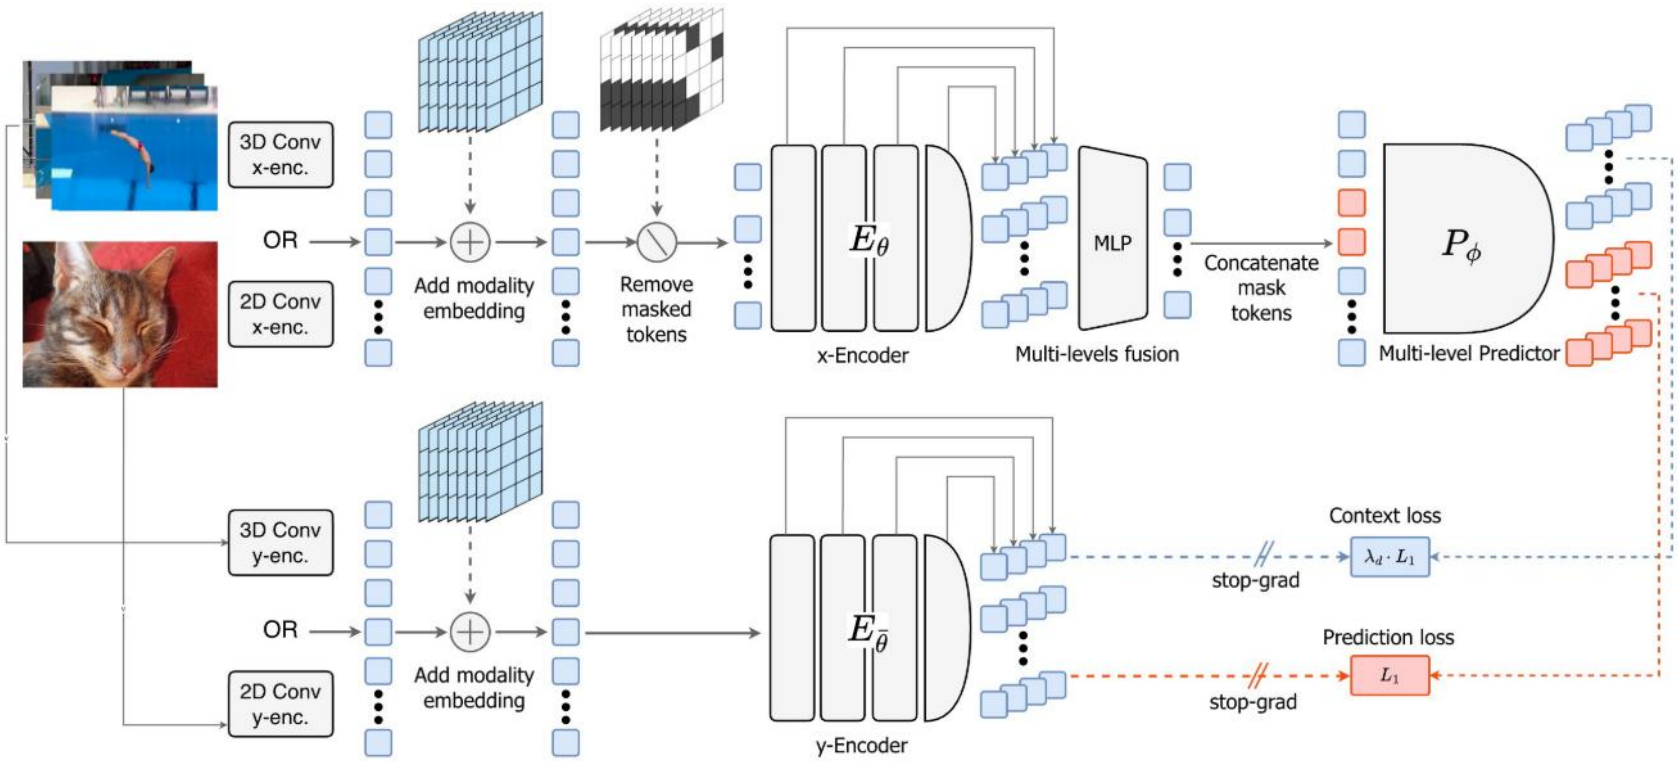
联合嵌入预测架构（V-JEPA 2.1）

AVC Lab
Affective Vision Computing Lab

V-JEPA 2 的密集特征碎片化 — 只在掩码token上算loss，可见区域无监督，局部空间结构差。V-JEPA 2.1能够学习图像和视频中视觉场景的密集、高质量表示，同时保持强大的全局场景理解能力。

1 密集预测损失
掩码 + 可见上下文 token 都参与 loss，显式空间时间接地

2 深度自监督 Deep Self-Supervision
编码器中间层也加监督，多层级预测提升特征质量



3 多模态 Tokenizers
图像和视频用不同的模态特定的 patch embedding，统一训练

4 模型与数据扩展
模型规模扩展到 ViT-G 使下游任务性能 SOTA 且可以有效蒸馏到更小的模型；更多样更平衡 image-video 训练分布数据集 VisionMix163M

JEPA 2.1的密集预测损失

AVC Lab
Affective Vision Computing Lab

掩码patch预测损失：

$$\hat{z}_{\text{target}} = g_\phi(f_\theta(x_{\text{context}}))$$

$$\mathcal{L}_{pred} = \left\| \hat{z}_{target} - sg[f_{\bar{\theta}}(x)]_{target} \right\|_1$$

$$\mathcal{L}_{pred} = \frac{1}{|M|} \sum_{i \in M} \left\| \hat{z}_{target,i} - sg[f_{\bar{\theta}}(x)]_{target,i} \right\|_1$$

可见上下文patch预测损失：

$$\hat{z}_{\text{context}} = g_\phi(f_\theta(x_{\text{context}}))$$

$$\mathcal{L}_{context} = \left\| \hat{z}_{content} - sg[f_{\bar{\theta}}(x)]_{\text{context}} \right\|_1$$

$$\mathcal{L}_{\text{context}} = \frac{1}{|C|} \sum_{i \in C} \lambda_i \left\| \hat{z}_{\text{context},i} - sg[f_{\bar{\theta}}(x)]_{\text{context},i} \right\|_1$$

密集预测损失：

$$\mathcal{L} = \mathcal{L}_{pred} + \mathcal{L}_{context}$$

引入显示可见上下文自监督，能够使模型学习编码连贯的局部结构特征，显著提高了密集预测任务的性能。

V-JEPA：把潜在表示预测扩展到视频

AVC Lab
Affective Vision Computing Lab

模型	输入与任务	与本文的关系
I-JEPA	图像区域的表示预测	JEPA 在图像上的实例
V-JEPA 系列	视频时空区域的表示预测	提供视频表征基础
V-JEPA 2.1	视频预测加稠密上下文监督	Human-JEPA 的初始化
Human-JEPA	人体领域继续训练与未来表示预测	改变目标来源与掩码

- **视频遮挡重建与严格未来预测的区别，在于目标时间段是否完全不可见。**
- **Human-JEPA继承V-JEPA 2.1的架构与初始化，重点研究继续预训练的目标和掩码。**

04

研究方法

方法总览：从V-JEPA 2.1到Human-JEPA

AVC Lab
Affective Vision Computing Lab

不改变架构与参数量，只做两个改变和一个省略：

输入：以人为中心的数据

- **视频分支**：包含16.4万单人动作片段+8.2万双人交互片段（均来自Kinetics-700）+AIST++舞蹈动作片段
- **图像分支**：95.8万张LUPerson-T高清单人裁切图，渲染为单帧视频片段

初始化：继承 V-JEPA 2.1

- 继承V-JEPA 2.1的编码器和预测器
- 学生编码器与预测器继续训练
- 保留一份冻结的初始编码器f_0作为稠密表征锚点
- 模型架构与参数规模保持不变

训练目标：人体感知+未来预测

- 根据过去视频预测未来潜在表示
- 可见位置的稠密特征锚定到冻结初始模型
- 全过程采用自监督学习
- **不使用人体标签或姿态标注**

创新 1 • 密集上下文锚定与图像联合训练

- Human-JEPA将上下文Loss的监督目标锁死在初始模型的彻底冻结副本f_0上
- Human-JEPA引入95.8万高清单人裁切图渲染为单帧Clip与视频共同训练

创新 2 • 预测掩码（过去 → 未来）

纯过去-未来分割替代空间块掩码，强迫模型对场景真实的运动动态建模

省略 • 无person-level 掩码

无 person-level 掩码、无 pose 输入，保持纯视频自监督

V-JEPA 属于预测式世界模型的一条路线，它不是直接生成未来像素，而是在 latent space 中预测未来表示；Human-JEPA 在此基础上进一步把这种时序预测能力专门化到人体场景。

方法出发点：两类继续训练风险

AVC Lab
Affective Vision Computing Lab

风险一：感知目标随模型漂移

学生改变，EMA上下文目标也改变，原有稠密表征失去固定参照。

风险二：掩码允许利用外观补全

各时刻都留有部分空间上下文，训练可能偏向外观复制。



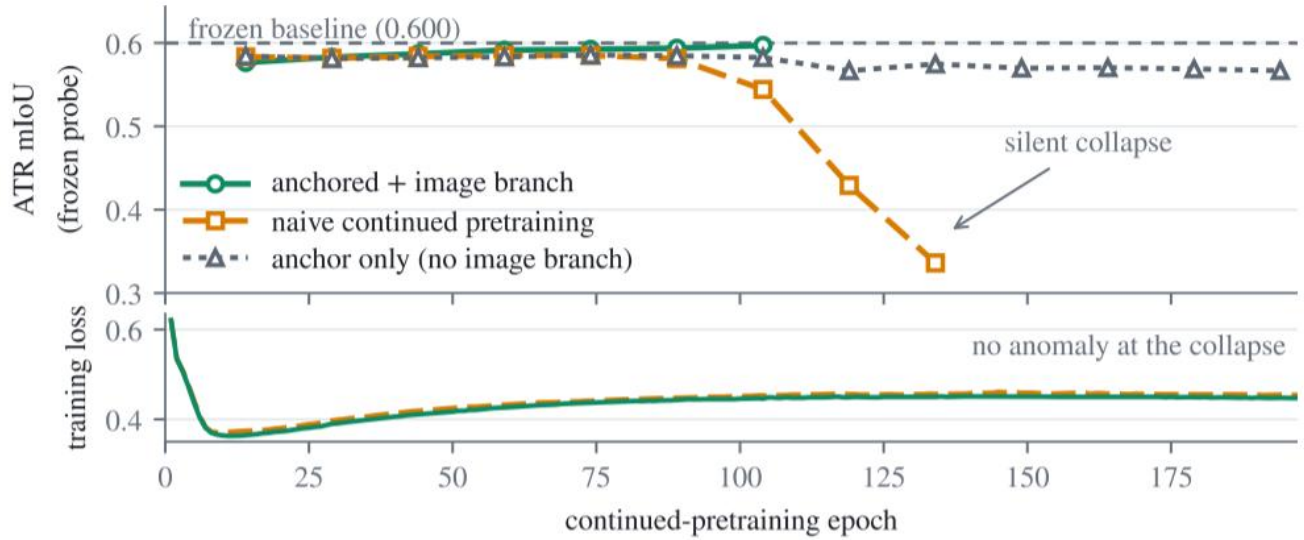
对应设计：固定可见位置的感知参照，并完全隐藏未来时间段。

创新1 密集上下文锚定与图像联合训练

AVC Lab
Affective Vision Computing Lab

问题：为什么不能直接在人体数据上继续训练?

直接继续预训练会导致**静默坍塌（silent collapse）：训练损失不断下降，但下游密集感知能力（如姿态估计、部位解析）约90轮后开始明显退化**，且训练过程中没有任何异常信号可以预警。



① Human-JEPA将上下文Loss的监督目标锁死在初始模型的彻底冻结副本f_0上，成功将密集特征固定在初始强感知水平，彻底阻断了表征崩溃。

$$\hat{z} = g_{\phi}(f_{\theta}(x_{ctx}))$$

$$A = f_0$$

$$\mathcal{L} = \underbrace{\|\hat{z}_{msk} - sg[f_{\bar{\theta}}(x)]_{msk}\|_1}_{masked\ prediction} + \lambda \underbrace{\|\hat{z}_{ctx} - sg[A(x)]_{ctx}\|_1}_{context\ (dense)\ loss}$$

② 增加高清单人图像联合训练分支，为模型不断地重新锚定高分辨率外观与身份特征，解决了视频模型画质糊、身份丢失的痛点。

创新2 预测掩码（从局部补全到未来预测）

AVC Lab
Affective Vision Computing Lab

Block mask（对照）

每个时间步都保留相似的空间上下文



可走的捷径：时空复制

传统 Block Mask（块掩码）

- 同一空间区域跨时间重复遮挡
- 其他时刻仍保留相似空间邻域
- predictor容易通过复制外观完成预测
- **结果：约5-point action tax，ReID大幅下降**

Forecast mask（Human-JEPA）

前半段可见，后半段完全不可见



唯一有效途径：建模 scene evolution

Forecasting Mask（预测掩码）

- 前半段作为context，后半段作为target
- 未来完全不可见，无法利用未来邻域做插值
- 迫使模型学习人体与场景随时间的演化
- **结果：action恢复接近base,ReID避免塌陷并提升**

预测目标：只用过去预测未来

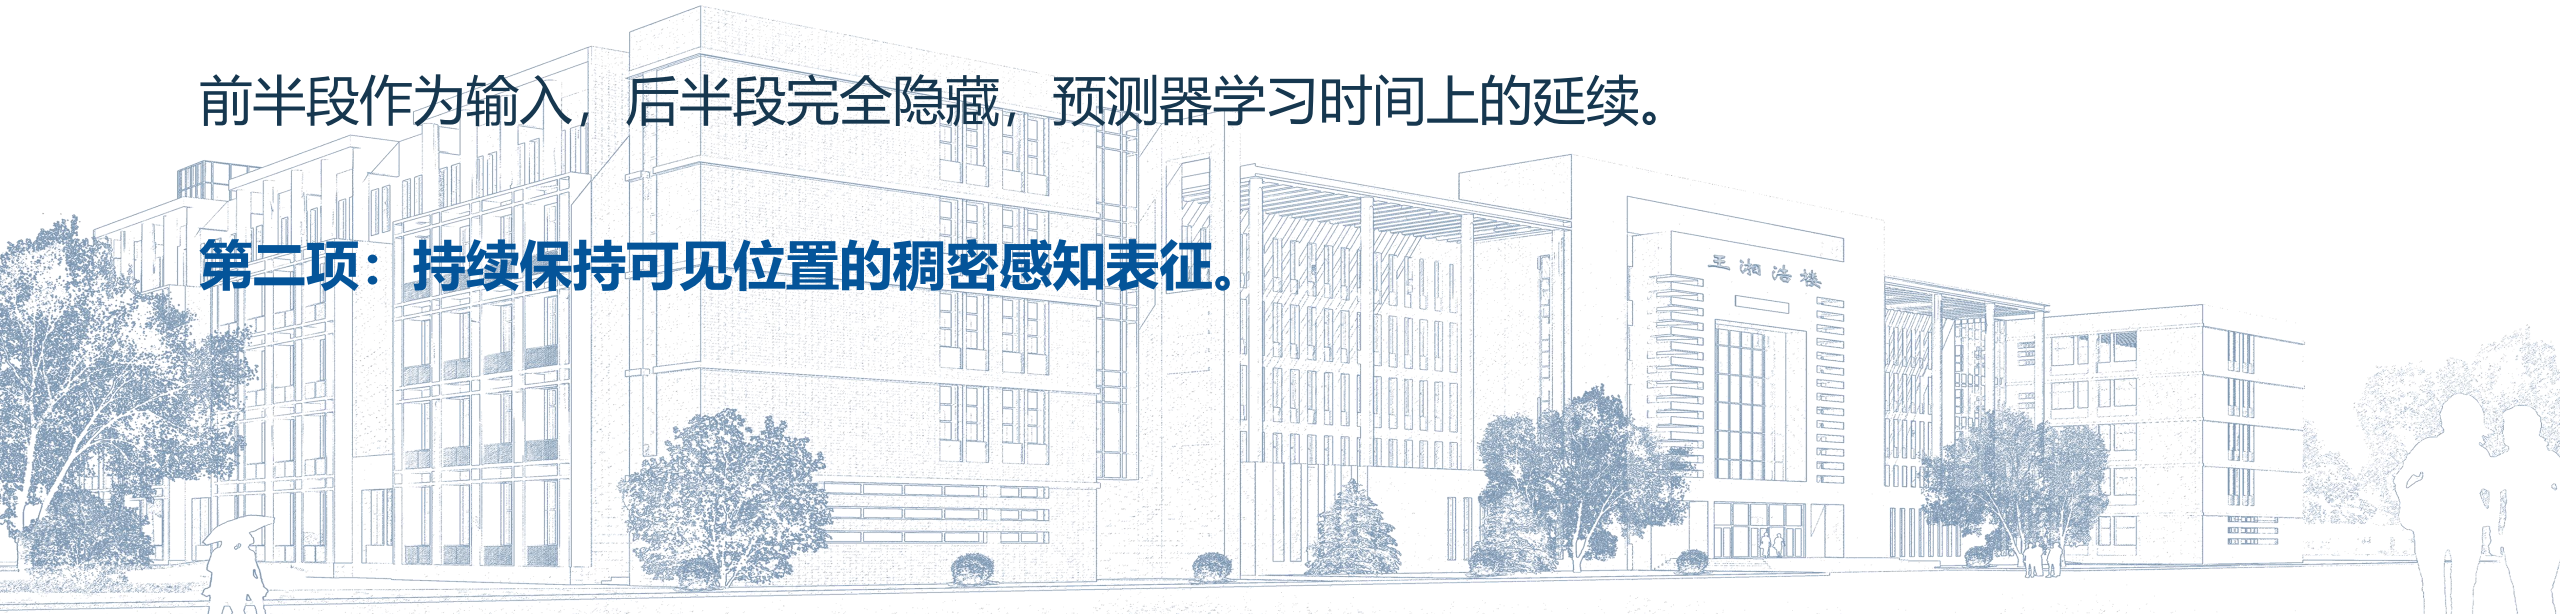
AVC Lab
Affective Vision Computing Lab

$$\mathcal{L} = \left\| g_\phi\left(f_\theta(x_{t<T/2})\right) - sg[f_{\bar{\theta}}(x)]_{t\geq T/2} \right\|_1 + \lambda \left\| \hat{z}_{ctx} - sg[f_0(x)]_{ctx} \right\|_1$$

第一项：学习未来表示

前半段作为输入，后半段完全隐藏，预测器学习时间上的延续。

第二项：持续保持可见位置的稠密感知表征。



Human-JEPA 一次视频分支训练迭代

AVC Lab
Affective Vision Computing Lab

1 采样与遮挡 16 帧视频划分为时空 token，前半段作为 context，后半段作为 future target。

2 产生预测 学生编码器提取 context 表征，预测器产生未来位置及可见 context 位置的预测表征。

3 构造目标 EMA 教师提供未来 target；冻结初始化模型f_0提供可见位置的 dense anchor target。

4 计算损失 未来预测损失与上下文密集锚点损失加权求和

5 更新模型 梯度更新学生编码器与预测器；EMA 更新教师编码器；f_0始终冻结。

人体图像分支与视频分支协同训练；最终编码器用于人体感知，预测器用于未来隐空间表征预测。

05

实验与分析

预训练数据

AVC Lab
Affective Vision Computing Lab

输入规格：16 frames，4 fps , 256×256

来源	筛选后规模	视频采样权重
Kinetics-700 全身片段	164,431 个	0.60
Kinetics-700 双人交互片段	82,696 个	0.35
AIST++ 舞蹈视频	作为额外运动数据，正文未报告片段总数	0.05
LUPerson-T 图像分支	约958,000个高清单人裁切图	单独的图像批次

基线选择与目的

AVC Lab
Affective Vision Computing Lab

Human-JEPA 是 0.3B，而 Sapiens2 是 0.8B，所以 Sapiens2 参数量大约是 Human-JEPA 的 2.7 倍。

基线	参照作用	比较时的注意点
V-JEPA 2.1-L，0.3B	隔离人体适配的额外收益	最直接的增量比较
Sapiens2，0.8B	人体图像专家的能力位置	参数规模与训练方式不同
DINOv3-L，0.3B	同规模通用视觉与身份参照	ReID和密集感知强
HAP ViT-B，0.09B	人体先验方法参照	规模不同，部分指标未评测

统一评估协议：谁预训练得到的表示本身更好?

AVC Lab
Affective Vision Computing Lab

所有 backbone 全部冻结，然后针对不同任务训练相同类型的轻量探针 probe。

任务组	数据与读出方式	检验内容
密集人体感知	ATR（线性探针/DPT探针）、DensePose（DPT探针）	空间结构与人体外观细节
姿态与身份ReID	COCO关键点、Market-1501	人体配置与人物辨识
完整视频动作	NTU-120、26类双人交互子集、Kinetics-700	完整视频与交互表征
早期动作预测	NTU-120，仅观察视频前半段	有限观察下的未来动作表征

骨干冻结，任务头、训练预算与评估子集统一。

实验概览

AVC Lab
Affective Vision Computing Lab

1 总体人体表征：Human-JEPA能否同时做好人体感知和动态理解?

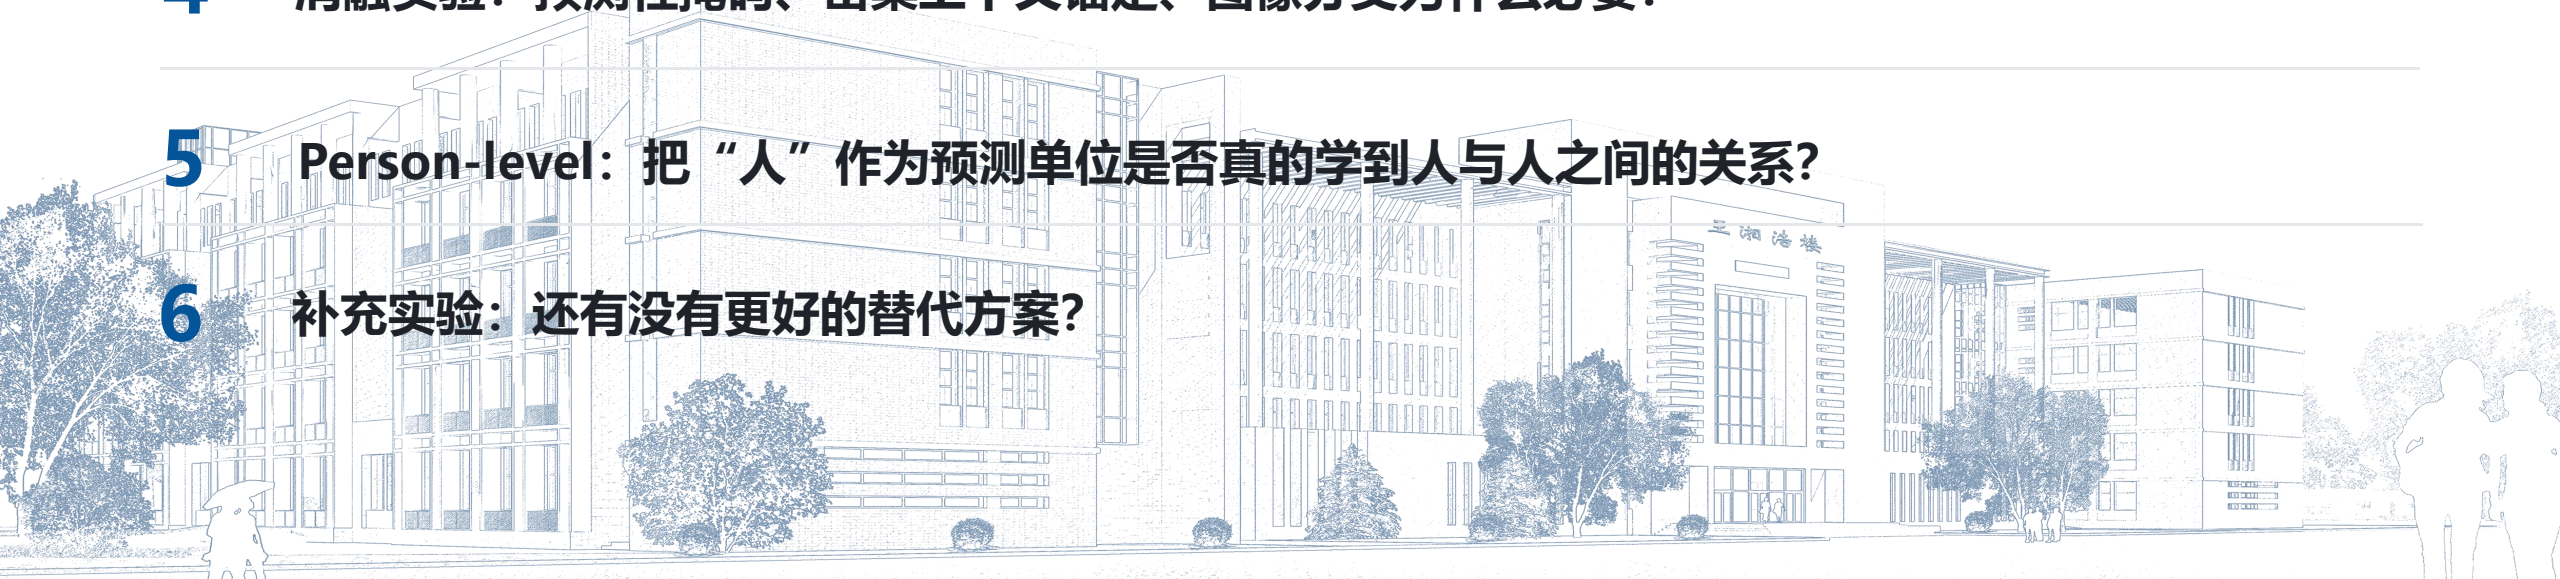
2 人体专有化是否真正增强身份(ReID)?

3 预测器Predictor是否真的会预测未来?

4 消融实验：预测性掩码、密集上下文锚定、图像分支为什么必要?

5 Person-level：把“人”作为预测单位是否真的学到人与人之间的关系?

6 补充实验：还有没有更好的替代方案?



总体人体表征：Human-JEPA能否同时做好人体感知和动态理解?

AVC Lab
Affective Vision Computing Lab

- **在姿态估计上：**Human-JEPA 0.620 领先 Sapiens2 0.591,但是绝大多数优势是因为V-JEPA 2.1本身就很强
- **行人重识别ReID：**相比V-JEPA 2.1大幅提升+2.7 mAP（高清单人图像分支生效，实现了对静态专家Sapiens2的全面反超）
- **密集感知能力ATR/DensePose：**Human-JEPA 不如 Sapiens2 / DINOv3
- **结论：**以像素为锚点的单图预训练主导高分辨率下的静态外观，而隐空间视频预测主导动态演化

Model	Params	ATR mIoU ↑	DensePose mIoU ↑	Pose AP ↑	NTU top-1 ↑	Mutual top-1 ↑	ReID mAP ↑
Human-centric image encoders							
Sapiens2-0.8B	0.8B	**.767**	**.666**	.591	n/a	n/a	.4522
DINOv3-L	0.3B	.766	.661	.564	n/a	n/a	**.5148**
HAP ViT-B	0.09B	.685	.492	.490	n/a	n/a	n/a
Video JEPA							
V-JEPA 2.1-L (base)	0.3B	.748	.649	.614	**70.8**	**79.6**	.4370
Human-JEPA (ours)	0.3B	.739±.004	.630±.004	**.620±.003**	68.2±2.3	77.5±1.6	.4635

人体专有化是否真正增强身份(ReID)?

AVC Lab
Affective Vision Computing Lab

- 在重识别上，Human-JEPA不仅超越了V-JEPA 2.1,还反超了Sapiens2，而身份信号来源于95.8万张LUPerson-T高清单人裁切图作为单帧Clip联合训练，提升了身份识别能力
- 仅仅把Mask换成传统的Block Mask，ReID得分会从0.4370暴跌到0.2666 mAP。原因：传统Block Mask允许模型在同一帧或相邻帧的空间邻域内，通过直接“复制周围外观”来降低训练 Loss

Model	mAP ↑	Rank-1 ↑	Rank-5 ↑
DINOv3-L	**.5148**	**.7586**	**.9074**
Sapiens2-0.8B	.4522	.7055	.8744
V-JEPA 2.1-L (base)	.4370	.6974	.8702
Human-JEPA (ours)	.4635	.7043	.8798
block-mask variant (A1)	.2666	.5235	.7271

预测器Predictor是否真的会预测未来?

AVC Lab
Affective Vision Computing Lab

模型随附的 Predictor 究竟能不能直接用?

Model	Encoder only top-1 ↑	Encoder + shipped head top-1 ↑	Effect of the head Δ top-1
V-JEPA 2.1-L (base)	78.91	75.93	−2.98
Human-JEPA (ours)	79.93	**79.99**	+0.06

NTU-120 早期动作预测（只给模型看视频前半段，然后让一个冻结的探针分类头去判断动作最终属于哪一类？）

Human-JEPA在自身的Latent空间内进行Forecasting 训练，Predictor预测出的向量与Encoder处于同一个向量空间，因此挂载Predictor绝不损害特征空间（+0.06 分），实现了完美的**表征空间连贯性。**

Predictor 猜出的未来特征是真预测还是在抄袭上一帧?

Human-JEPA预测真正未来

0.873（整体平均余弦相似度）

↑

假设完全不动，当前latent直接复制到未来

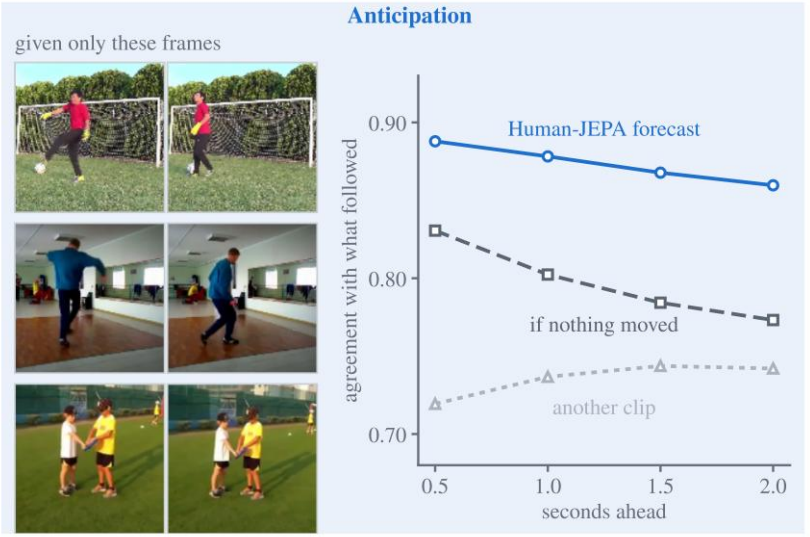
0.798（整体平均余弦相似度）

↑

Human-JEPA的预测和另一个无关视频的未来比较

0.735（整体平均余弦相似度）

结论：预测的潜在表示包含真实未来的时序信息



消融实验：预测性掩码、密集上下文锚定、图像分支为什么必要?

AVC Lab
Affective Vision Computing Lab

预测性掩码为什么必要?

动作识别性能：

Model	NTU top-1 ↑	mutual ↑	non-mutual ↑
A0: V-JEPA 2.1-L (frozen)	**70.8**	**79.6**	**68.1**
A1: anchored block-mask adaptation	65.6	74.7	62.8
whole-person deletion (200 ep)	45.5	57.0	42.0
Human-JEPA	70.4	79.0	67.7

块状掩码造成动作税Action Tax下降5.2个点，预测性掩码使动作识别性能几乎回到base的水平。

行人重识别性能：

Model	mAP ↑	Rank-1 ↑	Rank-5 ↑
DINOv3-L	**.5148**	**.7586**	**.9074**
Sapiens2-0.8B	.4522	.7055	.8744
V-JEPA 2.1-L (base)	.4370	.6974	.8702
Human-JEPA (ours)	.4635	.7043	.8798
block-mask variant (A1)	.2666	.5235	.7271

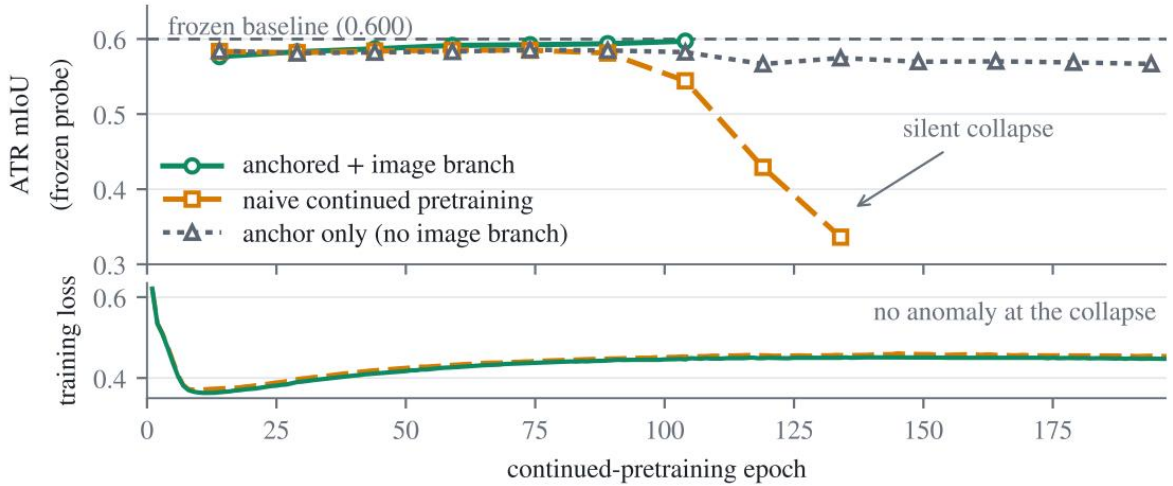
块状掩码还导致ReID身份特征崩塌

传统视频块状掩码允许模型在相邻帧之间偷懒复制，把算力浪费在简单的图像修复，改用预测性掩码后，强迫模型对场景真实演化建模。

消融实验：预测性掩码、密集上下文锚定、图像分支为什么必要?

AVC Lab
Affective Vision Computing Lab

密集上下文锚定和图像分支为什么必要?



密集上下文锚定消除了导致崩溃的动态漂移目标，可以阻止原生继续预训练出现的突然静默坍塌

Arm	Params	ATR-lin ↑	ATR-DPT ↑	DensePose ↑	Pose AP ↑	NTU ↑
A0: V-JEPA 2.1-L (frozen)	0.3B	.6230	.7479	.6490	.6142	70.8
C: naive continued PT (uncurated)	0.3B	.2947	.5907	.3534	.1105	66.5
C_{img}: C + image branch	0.3B	.6223	.7415	.6367	.6262	65.4
anchor only (no image branch)	0.3B	n/a	.709	n/a	.554	61.9
A1: anchored block-mask adaptation	0.3B	.6235	.7452	.6384	**.6279**	65.6
Human-JEPA	0.3B	.6210	.7433	.6333	.6233	70.4

图像分支不断重新锚定被视频预测磨灭的高清外观与ReID身份细节；锚定避免快速坍塌，两者作用互补

图像分支单独就足以把很多指标救回来

把“人”作为预测单位是否真的学到人与人之间的关系?

AVC Lab
Affective Vision Computing Lab

动机：既然目标是human-centric model，那是不是应该把“整个人”作为预测单元?

Masking	Dense mIoU ↑	Pose AP ↑	Mutual top-1 ↑
random multiblock (default)	0.7423 ± 0.0010	n/a	56.5
random multiblock, blended corpus	0.7418	0.6185	55.8
part tubes (HAP-style control)	0.7357	n/a	n/a
whole person, $\|M\|$=1	0.7357	0.6132	56.4
whole person + trajectory prior	0.7363	0.6105	52.9
whole person + traj. prior, $\|M\|$=2	0.7354	0.6105	54.4
whole person + identity prior	0.7340	0.6132	51.5
random multiblock, blended (34 ep)	0.7439	0.6204	62.7
whole person, $\|M\|$=1 (34 ep)	0.7391	0.6224	58.5
whole person, $\|M\|$=1 (200 ep)	0.6996	0.5403	57.0
scene forecasting, no person mask (34 ep)	0.7413	0.6223	**69.7**
person forecasting, t_0 anchor (34 ep)	0.7394	0.6223	57.8

直觉上觉得“把整个人擦除”或者“喂骨架”和身份先验能让模型更懂人，但是：

- 由于整个人被擦除，Loss目标侧不再包含该人的Token，导致“双人协同运动”的训练信号完全消失。
- 提供骨架先验相当于直接给模型泄露了姿态答案，模型偷懒不再去学习深层语义。

预测整个场景的未来比只把人作为预测单元更有效。

因果伙伴消融探针

AVC Lab
Affective Vision Computing Lab

动机：但 benchmark 高是不是就说明用了 partner?

保持目标人物相同，仅移除伙伴上下文，观察预测误差的变化。

$$\Delta_{\text{partner}} = \frac{E_{\text{removed}} - E_{\text{visible}}}{E_{\text{visible}}} \times 100\%$$

E 表示预测误差

测试条件	伙伴使用程度	含义
野外视频，9种人物级设计	最高0.72%	任务得分未转化为明显伙伴依赖
NTU互作，场景未来预测	2.02%	耦合更强的数据更能体现伙伴信息
监督双人动作联合训练训练	0.37%	分类成功也可能缺少关系利用

任务做得很好，不代表真的学到了相关表示。当数据真的具有强耦合时，场景未来预测可以利用partner信息。

补充实验：还有没有更好的替代方案?

AVC Lab
Affective Vision Computing Lab

试验	设计目的	结果与作用
掩码混合	寻找密集外观与时间动态的兼顾点	形成外观–动态权衡，未发现同时优于两个端点的中间配置。
两阶段调度（先预测性掩码，后块状掩码）	降低不同随机种子下的方差，提高训练可复现性。	降低结果方差，但平均Pose/ReID 略有下降。
可变观测比例	检验predictor是否具备未见时间跨度的泛化能力	仅提升0.26个点，未达预设+2个点门槛
运动引导损失加权	强调运动区域，可能让模型更关注动态，按帧间差分幅度对forecast loss进行token-level重加权	所有探针变化不超过0.1点

最终发布方案采用纯过去→未来预测性掩码与单阶段训练；其余设计作为可选配置或负结果记录。

06

总结

总结与展望

AVC Lab
Affective Vision Computing Lab

核心结论

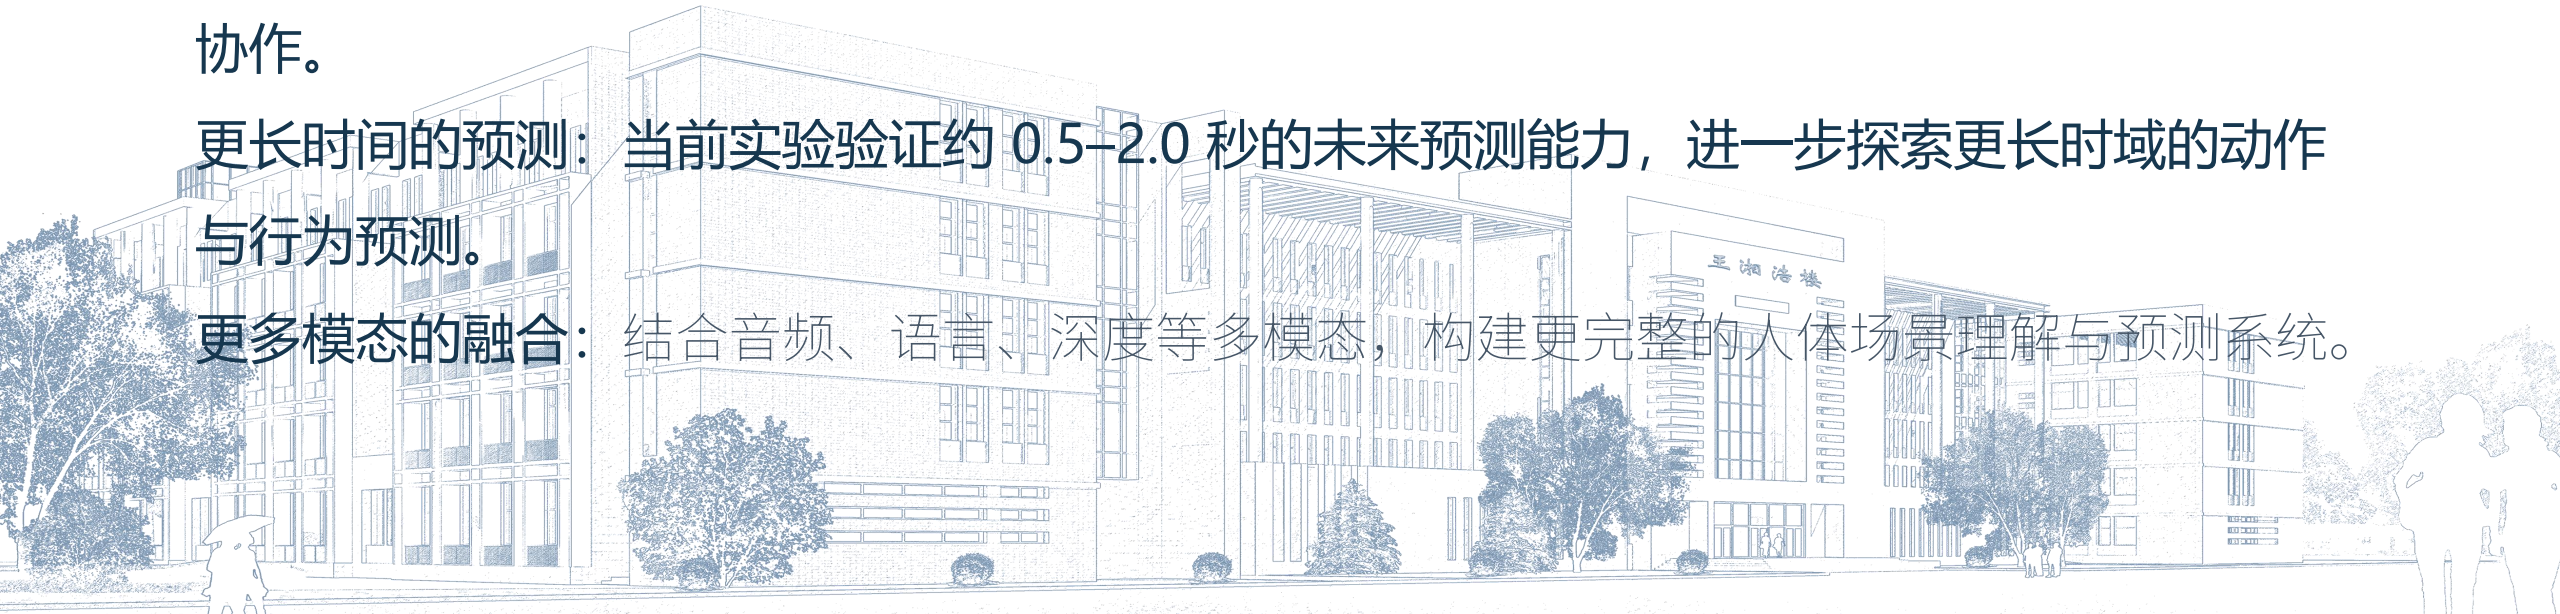
在保持V-JEPA 2.1原有架构的前提下，用密集上下文锚定、图像协同训练与未来预测实现人体当前感知与未来预测的统一建模。

值得继续研究的问题

具身智能与机器人：用于机器人操作中的人体动作预测，并进一步探索意图理解与安全人机协作。

更长时间的预测：当前实验验证约 0.5–2.0 秒的未来预测能力，进一步探索更长时域的动作与行为预测。

更多模态的融合：结合音频、语言、深度等多模态，构建更完整的人体场景理解与预测系统。



吉林大学
JILIN UNIVERSITY

谢谢！

